# ESTATÍSTICA APLICADA À CIÊNCIA DE DADOS II

Fatec 2026

# Objetivo:

- Realizar análise de regressão para identificar e quantificar o efeito das variáveis independentes sobre uma variável dependente
- Aplicar técnicas de análise multivariada para explorar e entender a relação entre múltiplas variáveis
- Utilizar técnicas de análise de séries temporais para analisar e prever dados ao longo do tempo.
- Interpretar e comunicar resultados estatísticos de forma clara e precisa
- Utilizar software estatístico e ferramentas computacionais para realizar análises estatísticas
- Compreender os princípios éticos e responsabilidades ao lidar com dados e resultados estatísticos

# Ementa:

- Análise de regressão: Modelagem de regressão linear simples e múltipla. Avaliação de modelos de regressão
- Interpretação e previsão utilizando modelos de regressão
- Análise multivariada: Análise de correlação e covariância. Análise de componentes principais
- Análise discriminante e clustering
- Análise de séries temporais: Conceitos básicos de séries temporais
- Modelagem e previsão de séries temporais
- Decomposição de séries temporais
- Software estatístico e ferramentas computacionais: Utilização de software estatístico para análise de dados
- Implementação de técnicas estatísticas em linguagens de programação
- Ética e responsabilidade na ciência de dados: Considerações éticas no uso de dados e análises estatísticas
- Privacidade, confidencialidade e segurança dos dados. Aplicações práticas em ciência de dados: Aplicação dos conceitos estatísticos em projetos de ciência de dados
- Análise de dados reais e tomada de decisões baseadas em evidências

# Avaliação

Exercícios semanais(Peso 4)
Projeto (Peso 4)
Prova bimestral(Peso 2)

# Estatística, a chave da nova revolução

1. **Revolução da Agricultura** → atualmente o mundo produz mais alimentos através de cultivos, do que através de caça.

2. **Revolução Industrial** → fábricas de produção em massa deram ao mundo uma imensa variedade de opções de produtos.

3. **Revolução da Informação** → a tecnologia nos deu uma grande variedade de produtos eletrônicos, tornou a indústria mais eficiente e aumentou consideravelmente a quantidade de informação a nossa disposição.

4. **Revolução Digital** → estamos no meio desta revolução e o volume de dados gerados pela humanidade, nos traz o desafio de conseguir extrair informação útil. A análise estatística é a chave desta revolução.

Habilidades

**Ciência dos Dados**

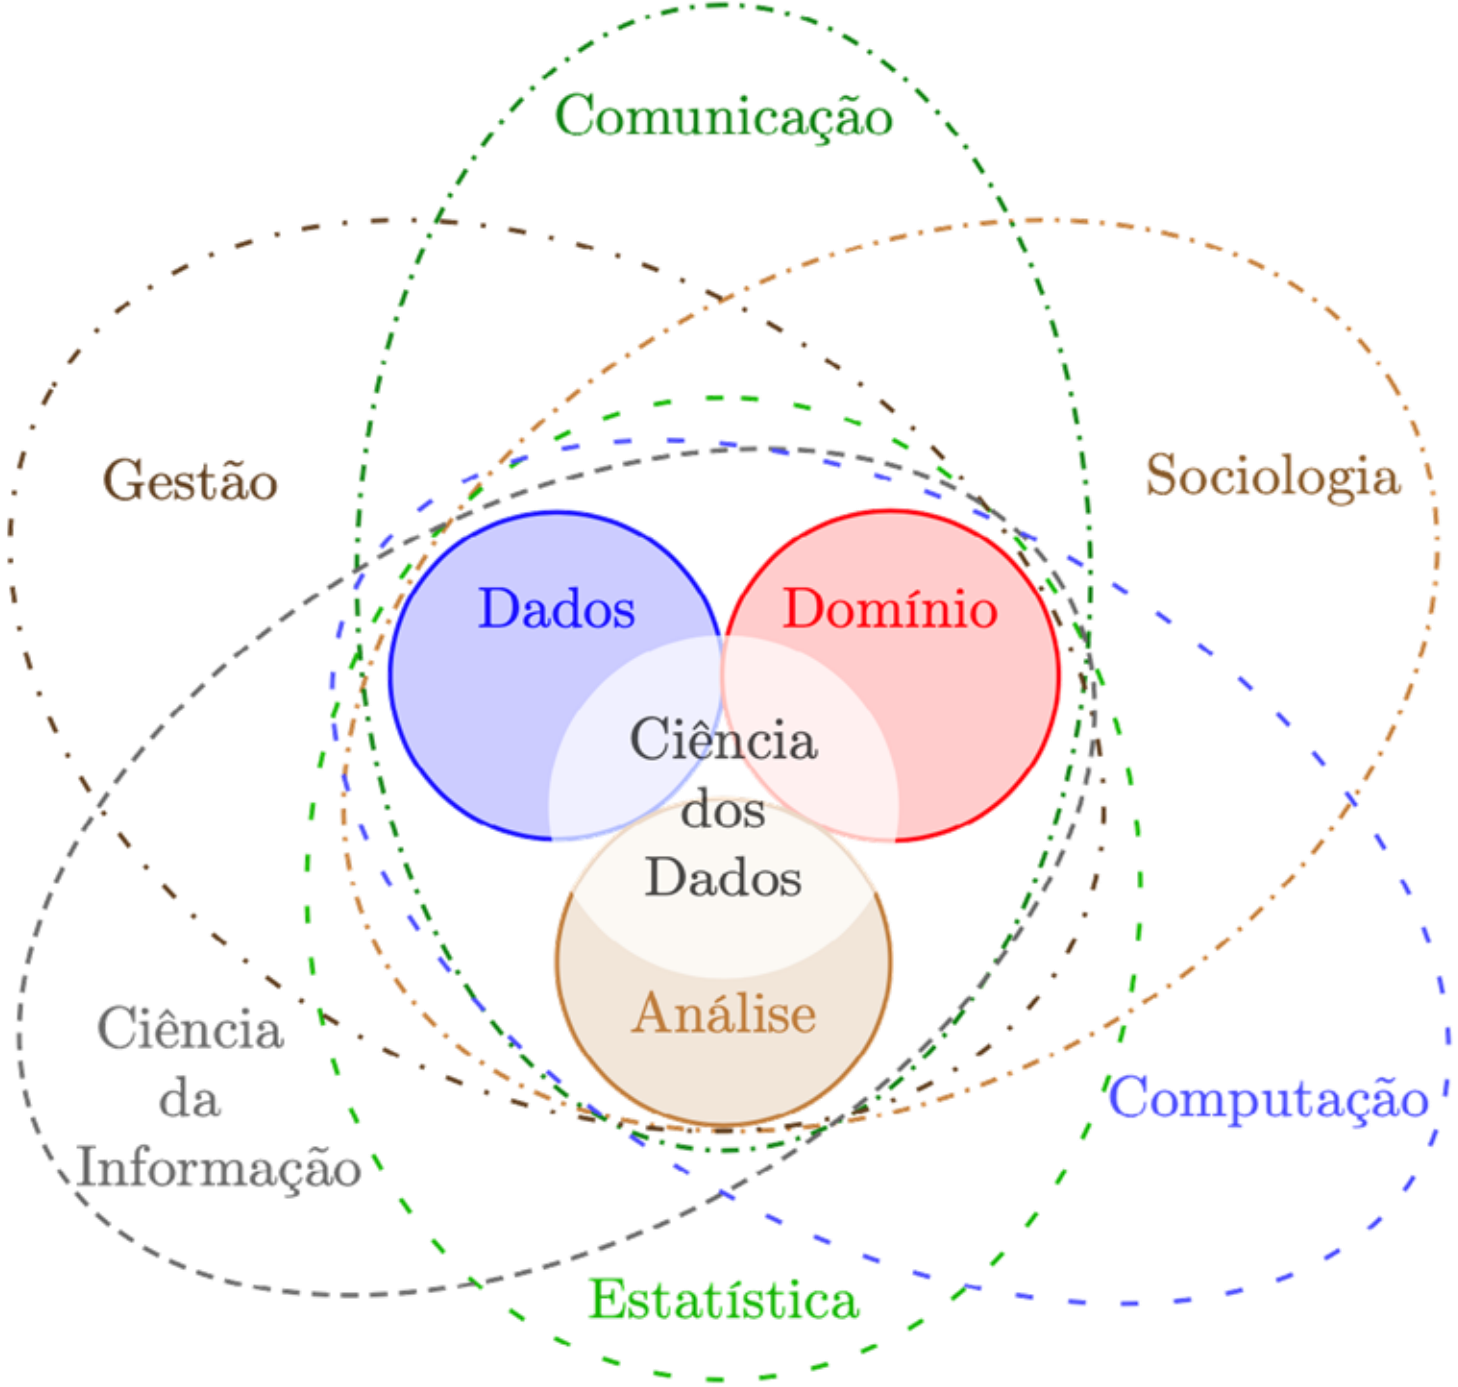

# O que é Analise de dados

- Arte de analisar dados crus e transformá-los em informação
- O objetivo da análise é sempre otimizar os resultados de um modelo

# Viés de sobrevivência **Abraham Wald – Segunda Guerra Mundial**

- Estatísticos da equipe de *Abraham Wald* analisavam todos os aviões que voltavam das batalhas
- Objetivo era identificar onde a estrutura dos aviões deveria ser reforçada da maneira mais eficiente
- Seria óbvio reforçar os locais onde há perfurações
- Mas esses aviões conseguiram voltar
- Ou seja, deve-se reforçar os locais que não tinham perfurações
- Esse caso ilustra o viés da sobrevivência (*survival bias),* um tipo de viés de seleção

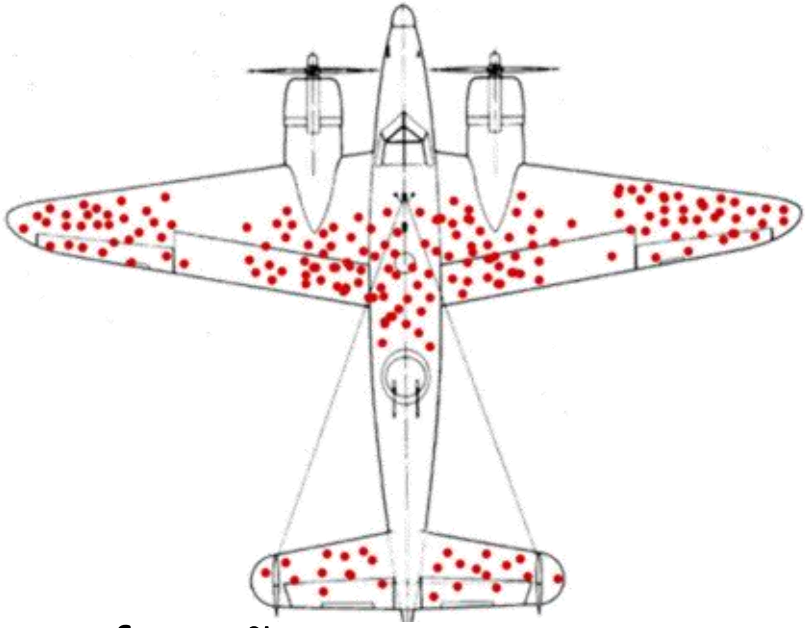

viés de seleção, consiste no erro lógico de nos concentrarmos em coisas ou pessoas que sobreviveram a algum processo enquanto ignoramos aqueles que foram eliminados devido a sua falta de visibilidade

Se usarmos a única fonte de informação disponível como sendo suficiente para uma hipótese, vamos ignorar grande parte das causas dos problemas. As vezes, a resposta mais importante está na informação que está faltando

# Estabelecendo Questionamentos

- Uma das tarefas mais comuns de um cientista de dados é descobrir padrões e obter insights a partir da análise exploratória de dados

- Durante este processo, os dados são avaliados de modo a se encontrar padrões, detectar anomalias e formular hipóteses

- Normalmente as técnicas de EDA são feitas por meio da visualização analítica

- A qualidade dos achados depende da habilidade do cientista em formular as questões corretas e realizar uma sequência de análises que possibilitem  respondr a elas!

# Framework de Análise Exploratória

**Modelo Mental**

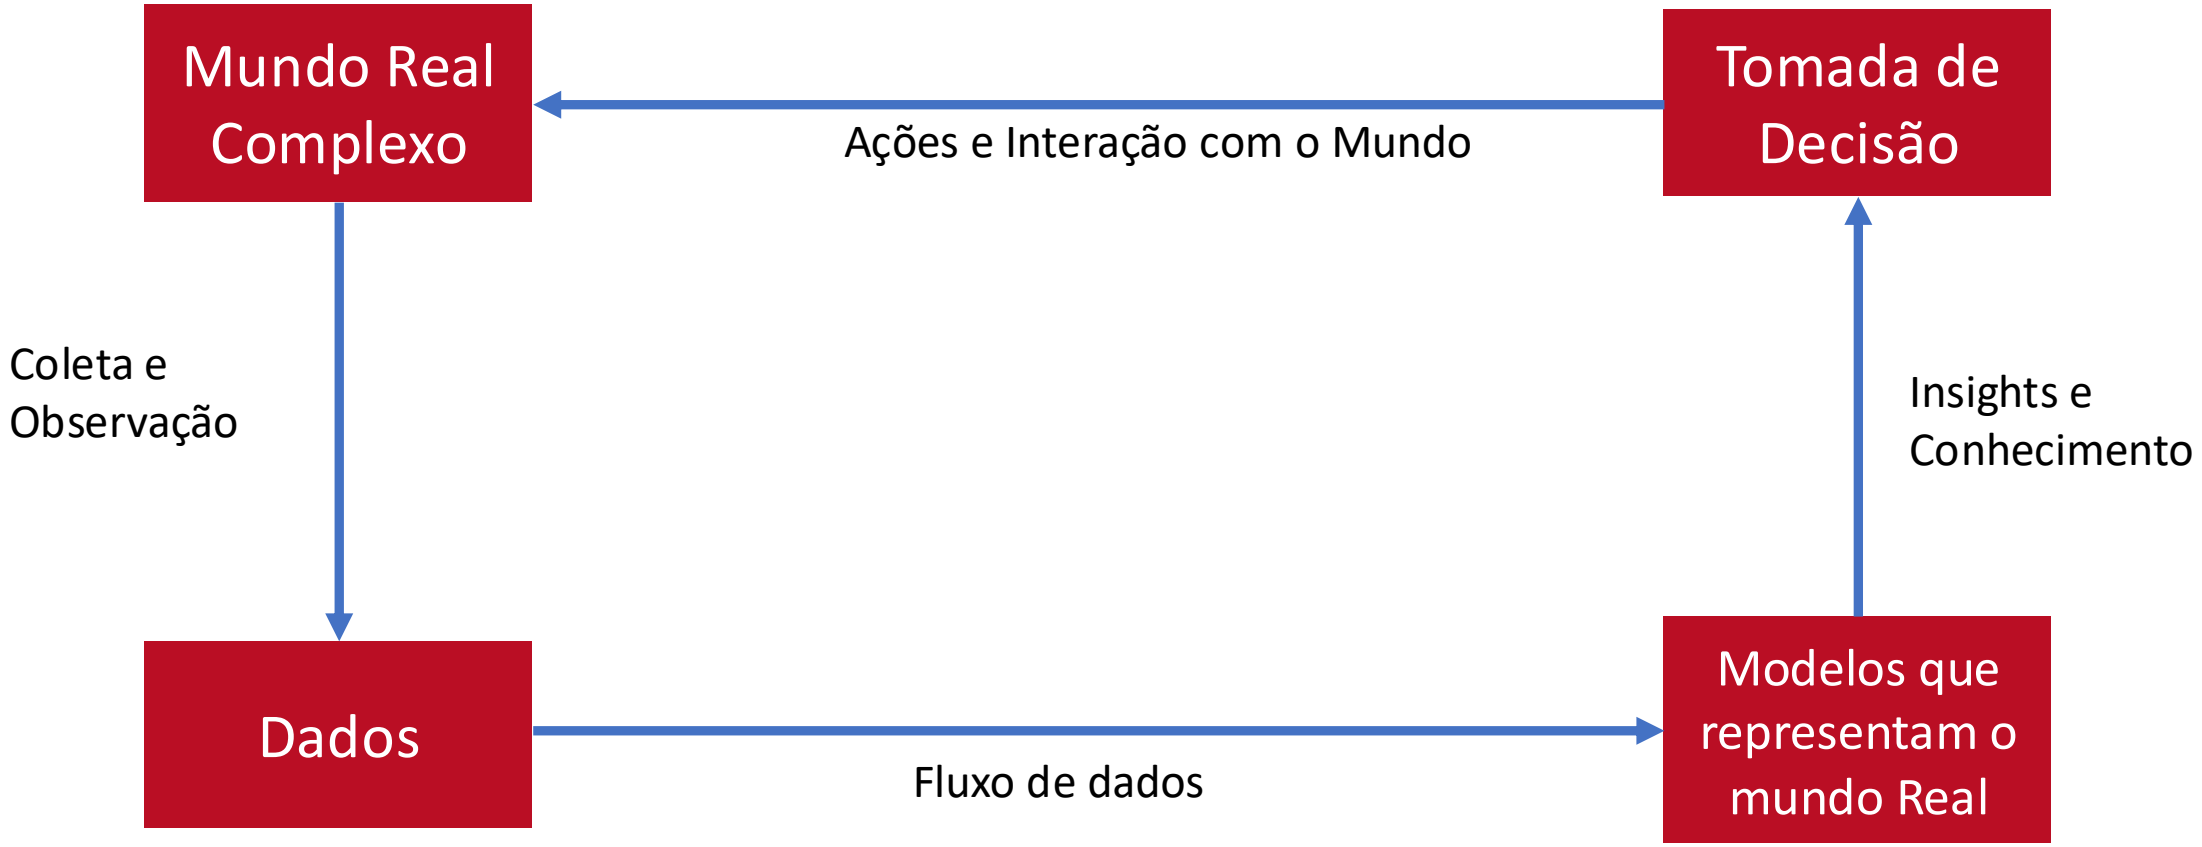

# Quais são as perguntas certas?

- Formule perguntas que possibilite compreender os dados e seus processos de transformação, ao passo em que constrói um background sobre o problema
- Por onde começar?
  - **Data Scrutiny / Description**
    - Avalie a estrutura e qualidade dos dados
      - Quantos registros? Quantas variáveis?
    - Como os dados foram coletados?
    - Qual o formato dos dados? Tipos de dados?
    - Há erros nos dados? Outliers? Valores únicos?
    - Missing data?
    - Calcule as estatísticas descritivas para os dados
    - Verifique a distribuição e comportamento dos dados
  - **Interaja com os dados** (auxiliado por estatística descritiva e visualização)

**a transformation can sometimes work wonders in deciphering the data**

Chatfield (1985)

# Quais são as perguntas certas?

- Qual o motivo da sua análise?
  - Explorar os dados ...
  - Otimizar algum resultado
  - Predizer algum desfecho
  - Etc.

- Além disso, você deve avaliar os dados e o problema que está formulando sobre os seguintes aspectos:
  - Riscos
  - Benefícios
  - Contingências
  - Regulamentações
  - Recursos
  - Requisitos

# Estabelecendo Questionamentos

- Análise Geral
  - Qual pergunta eu quero responder com essa estatística?
  - O que esta estatística significa?
  - Com o que uma observação mediana se parece? E quanto a uma observação extrema?
  - Qual o horizonte temporal?
- Desafiando premissas:
  - Valores maiores ou menores são melhores?
  - Valores estão dentro da expectativa esperada?
  - Quais premissas estou usando?
  - Quais os vieses da coleta de dados?

# Estabelecendo Questionamentos: evidências e ponto de vista

- Evidências
  - O quão forte é essa evidência?
  - Significância estatística x Relevância de negócio
  - O que está faltando nos meus dados? Quais dimensões não estão sendo levadas em conta?
- Perspectiva e ponto de vista
  - O que eu gostaria que os dados me falassem?
  - Como seriam os dados se a conclusão fosse diferente?
  - Se não existissem dados, o que eu faria?

# Análise exploratória de dados

# Fonte e formatos de dados

Images, videos, audio, Flash, live streams, podcasts, etc.

Twitter, Linkedin, Facebook, Tumblr, Blog, SlideShare, YouTube, Google+, Instagram, Flickr, Pinterest, Vimeo, WordPress, IM, RSS, Review, Chatter, Jive, Yammer, etc.

XLS, PDF, CSV, email, Word, PPT, HTML, HTML 5, plain text, XML, JSON, etc.

Medical devices, smart electric meters, car sensors, road cameras, satellites, traffic recording devices, processors found within vehicles, video games, cable boxes, assembly lines, office building, cell towers, jet engines, air conditioning units, refrigerators, trucks, farm machinery, etc..

Government, weather, competitive, traffic, regulatory, compliance, health care services, economic, census, public finance, stock, OSINT, the World Bank, SEC/Edgar, Wikipedia, IMDb, etc.

Event logs, server data, application logs, business process logs, audit logs, call detail records (CDRs), mobile location, mobile app usage, clickstream data, etc.

Archives of scanned documents, statements, insurance forms, medical record and customer correspondence, paper archives, and print stream files that contain original systems of record between organizations and their customers

Project management, marketing automation, productivity, CRM, ERP content management system, HR, storage, talent management, procurement, expense management Google Docs, intranets, portals, etc.

# Dados **Repositórios, Crawling e Scraping**

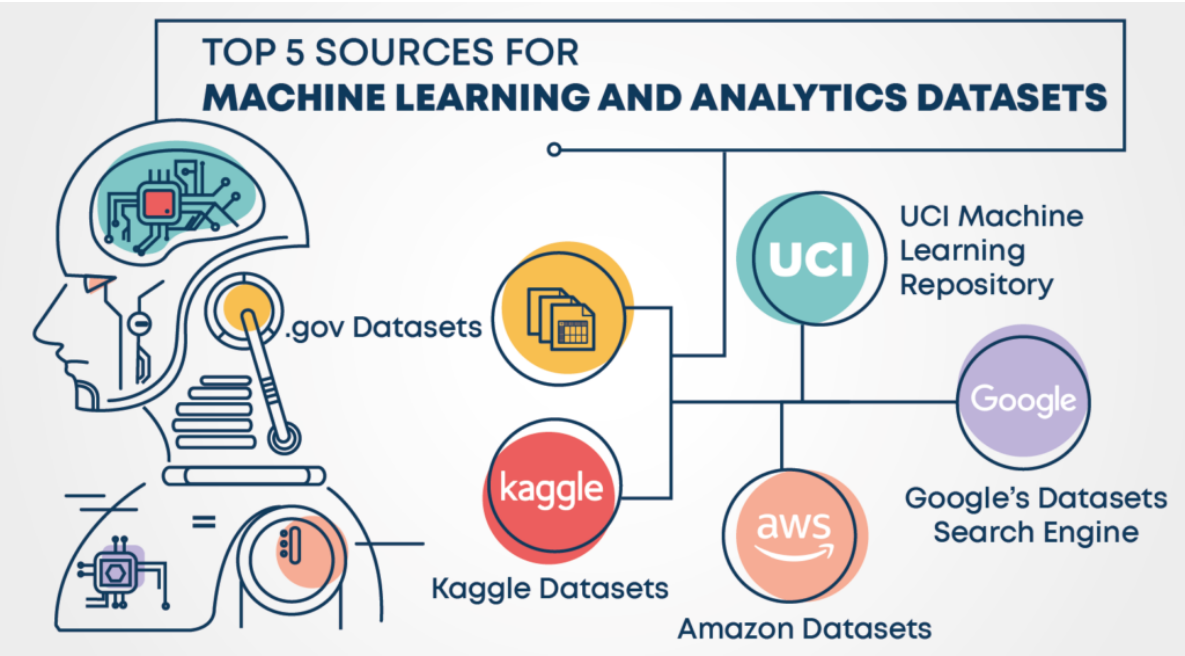

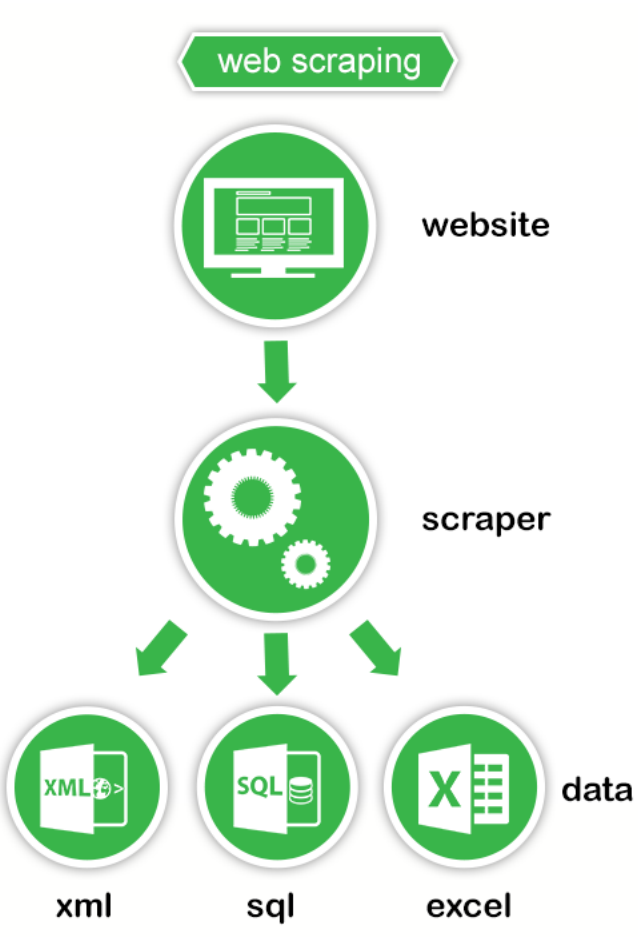

# Dados **Formato**

- Tabular

| x | y | tempo | red | green | blue |
|---|---|---|---|---|---|
| 0 | 0 | 0 | 255 | 0 | 0 |
| 0 | 1 | 0 | 200 | 10 | 6 |
| ... | | | | | |
| 0 | 0 | 0.1 | 255 | 50 | 100 |
| 0 | 1 | 0.1 | 255 | 200 | 190 |
| ... | | | | | |

**Tupla**,
ponto multidimensional,
Vetor,
Linha
Instância

Domínio
Variáveis independentes
**Dimensões**

Contradomínio
Variáveis dependentes
**Medidas**

Colunas, **Variáveis**

# Variáveis e observações

Variáveis

Observações

| | Idade | Sexo | Peso | Cor dos olhos |
|---|---|---|---|---|
| Indivíduo 1 | 42 | M | 59 | Verde |
| Indivíduo 2 | 34 | M | 54 | Castanho |
| Indivíduo 3 | 56 | F | 89 | Azul |
| Indivíduo 4 | 41 | M | 76 | Castanho |
| Indivíduo 5 | 23 | F | 65 | Castanho |

# Dados **Organização**

```
CASENO  OFFENSE EVENTDT EVENTTM CVLEGEND    CVDOW   InDbDate    Block_Location
BLKADDR City    State
18000273    VEHICLE STOLEN  01/01/2018 12:00:00 AM  20:30   MOTOR VEHICLE THEFT
1   01/24/2018 03:30:18 AM  "1100 PARKER ST
Berkeley, CA
(37.859364, -122.288914)"   1100 PARKER ST  Berkeley    CA
17092476    BURGLARY AUTO   12/12/2017 12:00:00 AM  13:30   BURGLARY - VEHICLE
2   01/24/2018 03:30:17 AM  "2300 LE CONTE AVE
```

## TSV

Tab separated values

```
CASENO,OFFENSE,EVENTDT,EVENTTM,CVLEGEND,CVDOW,InDbDate,Block_Location,BLKADDR,City,Stat
e
18000273,VEHICLE STOLEN,01/01/2018 12:00:00 AM,20:30,MOTOR VEHICLE THEFT,1,01/24/2018
03:30:18 AM,"1100 PARKER ST
Berkeley, CA
(37.859364, -122.288914)",1100 PARKER ST,Berkeley,CA
17092476,BURGLARY AUTO,12/12/2017 12:00:00 AM,13:30,BURGLARY - VEHICLE,2,01/24/2018
03:30:17 AM,"2300 LE CONTE AVE
Berkeley, CA
(37.874867, -122.263689)",2300 LE CONTE AVE,Berkeley,CA
17092534,BURGLARY AUTO,
03:30:17 AM,"1700 STUAR
Berkeley, CA
(37.857495, -122.275256
17091517,THEFT MISD. (U
03:30:11 AM,"1600 CALIF
Berkeley, CA
(37.876791, -122.280472
17048102,THEFT FROM AUT
```

## CSV

Comma separated values

## JSON

```
{
    "field1": "value1",
    "field2": ["list", "of", "values"],
    "myfield3": {"is_recursive": true, "a null value": null}
}
```

Line 5, Column 2 | 4 misspelled words | Spaces: 4 | JSON

JavaScript Object Notation

# Dados **Tipos de Dados**

- Os conjuntos de dados são compostos por dois tipos de dados: dados **qualitativos** e dados **quantitativos**

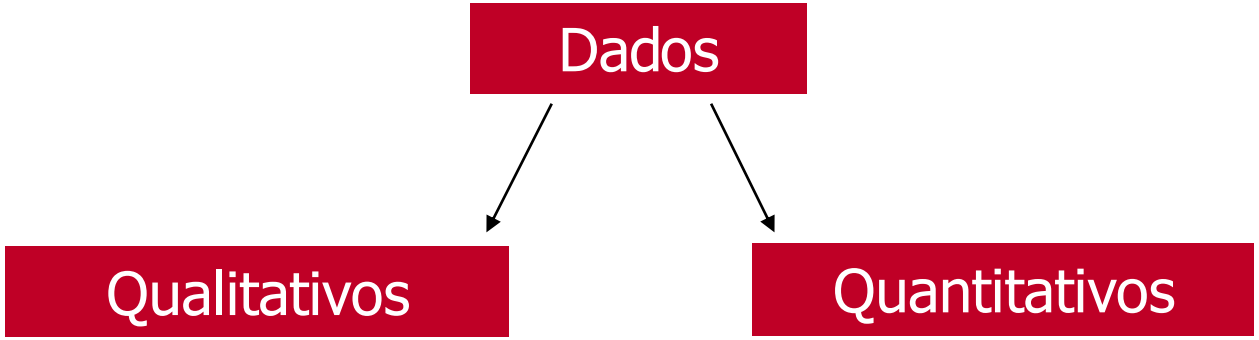


Consiste de atributos, rótulos ou entidades não numéricas

(Categóricos)

Consiste de medições numéricas ou contagens

(Numéricos)

# Dados **Tipos de Dados**

- Considere o seguinte exemplo
  - Notas de alunos em uma determinada disciplina

| Aluno | Nota |
|---|---|
| Sally | 3.22 |
| Bob | 3.98 |
| Cindy | 2.75 |
| Mark | 2.24 |
| Kathy | 3.84 |

**Qualitativo** **Quantitativo**

# Dados Quantitativos

## Tipos de Variáveis

Um dado classificado como "**idade**" é **quantitativo**
Ex:. 11, 15, 18, 25, 42 anos.

Entretanto, se esse dado for informado por "**faixa etária**" ele é **qualitativo** (ordinal).

Ex: 0 – 5 anos
6 – 12 anos
13 – 18 anos
19 – 28 anos

# Dados Quantitativos

**Descrevendo os dados numericamente**

- **Centralidade e Posição**
  - Média
  - Mediana
  - Moda
  - Média Ponderada
  - Percentís
  - Quartis
- **Dispersão**
  - Amplitude
  - Invervalo interquartil
  - Variância
  - Desvio Padrão

# Tipos de variáveis Qualitativas

Os dados podem conter variáveis:

**Qualitativas** – utilizam termos **descritivos** para descrever algo de interesse. Ex: cor dos olhos, estado civil, religião, sexo, grau de escolaridade, classe social, tipo sanguíneo, cor da pele, etc...

# Dados **Escalas de Medição**

- Há quatro escalas de medição de um dado, quais sejam:

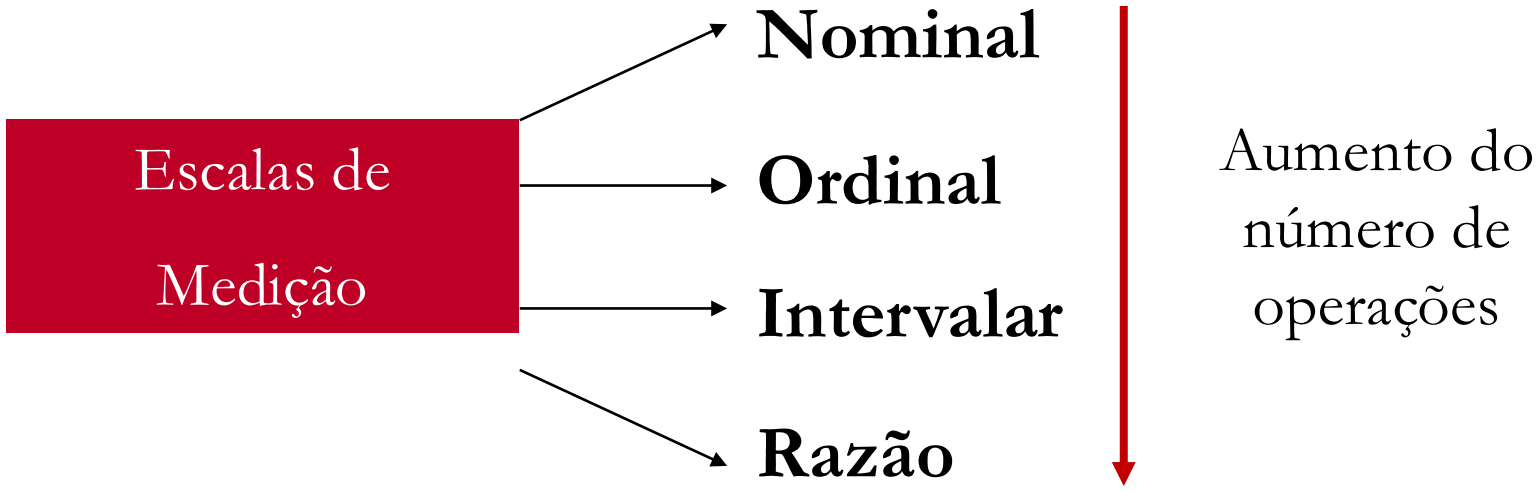

# Dados **Escala Nominal**

- Representam **categorias** que não mantém necessariamente relação entre elas
- Não é possível realizar operações aritméticas (soma, média, etc.)
- Normalmente realiza-se apenas a contagem das observações em cada categoria

Escalas de Medição

**Nominal**

Calculada usando nomes, rótulos ou categorias. Não há operações aritméticas feitas nesta escala.

Cores da bandeira do Brasil

Nomes dos alunos em uma classe

Livros que estamos lendo

# Dados **Escala Ordinal**

- **Categorias** podem ser representadas por nomes, símbolos ou números, porém há uma ordenação de uma categoria em relação à outra
- A distância entre uma categoria e a outra não pode ser medida numericamente
- Além da operação de contagem, permitem operações que envolvam ordenação (maior/menor)

Escalas de Medição

**Ordinal**

Podem ser ordenadas entre si, mas não é possível diferenciá-las numericamente.

Nível de experiência: junior, pleno e senior

Números das camisas dos jogadores da seleção

Top 10 músicas mais tocadas no momento

# Dados

## Escala Intervalar

- Escala **quantitativa**
- O valor nulo não corresponde à ausência da característica medida
- A escala possui um zero arbitrário
- Exemplo: 0 °**C** não significa ausência de temperatura (-273 °**C**)
- Operação de divisão é ilegítima em dados intervalares

Escalas de Medição

**Intervalar**

Ordenadas, a diferença entre duas medidas pode ser calculada

Temperatura

Linha do tempo em anos

40 ° não é o dobro de 20 °C.

Veja em Fahrenheit:

20 °C → 68°F

40 °C → 104 °F

# Dados

## Escala Razão

- Escala **quantitativa**
- O zero corresponde à ausência da característica medida
- É possível realizar todas as operações aritméticas em dados dessa escala

Escalas de Medição

**Razão**

Uma divisão entre dois valores pode ser realizada

Idade | Peso | Altura | Dinheiro

# Análise exploratória

| Nominal | Ordinal | Discreta | Contínua |
| --- | --- | --- | --- |
| – Cor<br>– Sexo<br>– Estado Civil<br>– Vale transporte (Sim ou Não)<br>– Grau de Escolaridade | – Escala de questionário<br>– Preferência<br>– Faixa etária<br>– Classe Social | – Escala de questionário (numérica)<br>– Número de filhos<br>– Quantidade de empregados<br>– Quantidade de ligações | – Salário Mensal<br>– Idade<br>– Anos de estudo<br>– Taxas |

# Análise Exploratória

Quantitativa

Qualitativas (categóricas)

| id | sexo | idade | cor | internet | Telefone móvel | Anos de estudo | Rendimento |
|---|---|---|---|---|---|---|---|
| 35000015 | 2 | 15 | 2 | 1 | 3 | 7 | 800 |
| 35000015 | 2 | 75 | 2 | 3 | 3 | 12 | 2.100 |
| 35000031 | 2 | 60 | 2 | 3 | 3 | 12 | 1.800 |
| 35000058 | 2 | 68 | 2 | 3 | 3 | 1 | |
| 35000058 | 2 | 48 | 8 | 3 | 1 | 5 | 1.000 |
| 35000058 | 2 | 42 | 2 | 3 | 3 | 6 | 900 |
| 35000066 | 2 | 36 | 2 | 1 | 3 | 9 | 1.000 |
| 35000066 | 2 | 44 | 2 | 1 | 1 | 9 | 1.200 |
| 35000066 | 2 | 20 | 2 | 1 | 3 | 13 | 300 |
| 35000066 | 4 | 26 | 2 | 1 | 3 | 12 | 1.900 |
| 35000074 | 4 | 14 | 2 | 1 | 3 | 8 | 700 |
| 35000074 | 4 | 71 | 2 | 3 | 3 | 5 | 450 |
| 35000090 | 4 | 20 | 2 | 1 | 1 | 12 | 1.890 |
| 35000090 | 2 | 19 | 8 | 1 | 3 | 12 | 620 |
| 35000090 | 4 | 42 | 2 | 3 | 1 | 12 | 300 |
| 35000090 | 4 | 17 | 2 | 1 | 1 | 11 | 1.100 |
| 35000090 | 4 | 25 | 2 | 1 | 1 | 12 | 433 |
| 35000090 | 2 | 49 | 6 | 1 | 3 | 16 | 400 |
| 35000104 | 2 | 38 | 2 | 3 | 1 | 6 | 600 |

# Transformando

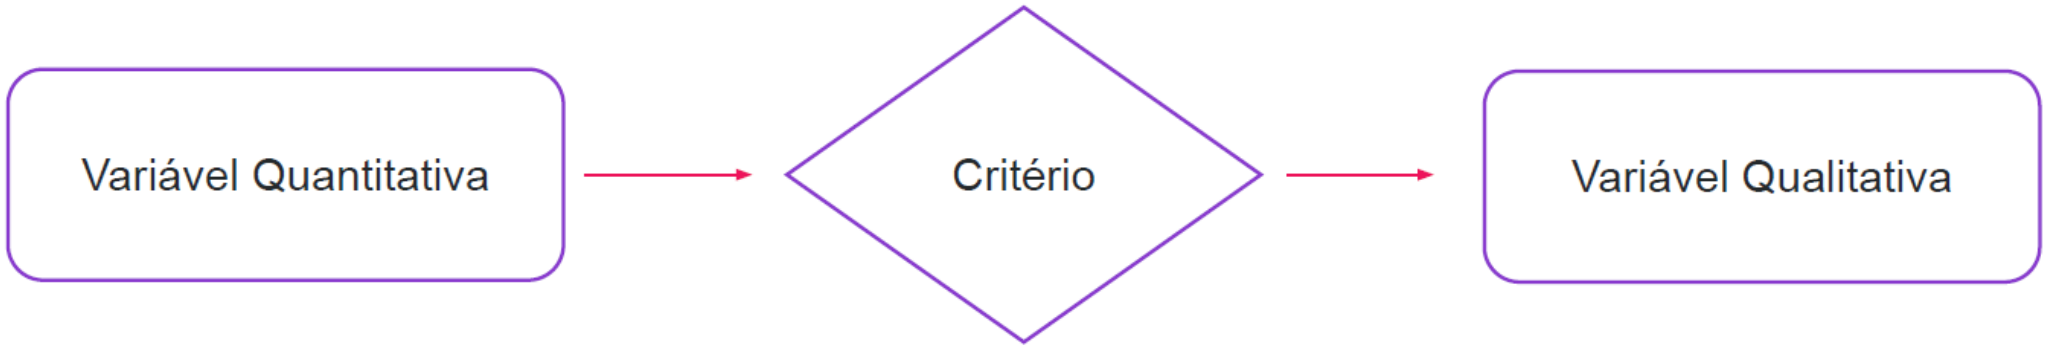


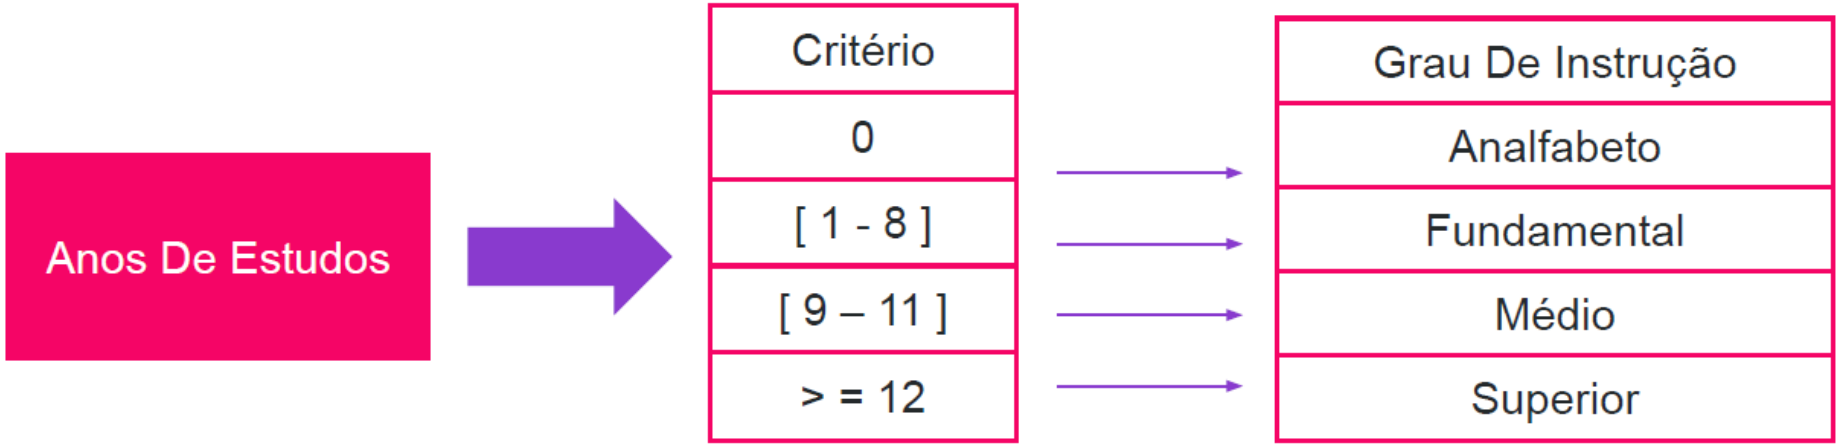

# Recapitulando...

- **O papel da Estatística:** Como ela se tornou a "chave" para extrair valor no meio da Revolução Digital
- **Habilidades do Cientista de Dados:** A importância de equilibrar Computação, Estatística e o Domínio do problema
- **Pensamento Crítico e Vieses:** O caso de Abraham Wald nos ensinou que o que não vemos nos dados pode ser a resposta mais importante
- **Tipagem de Dados e Escalas:** Como classificar variáveis em Qualitativas e Quantitativas
- **Ciclo de Vida de Análise:** Do entendimento do problema à comunicação dos resultados através da Análise Exploratória de Dados