ESTATÍSTICA APLICADA À CIÊNCIA DE DADOS II

Fatec 2026 – Análise exploratória

O que é Analise de dados

- Arte de analisar dados crus e transformá-los em informação
- O objetivo da análise é sempre otimizar os resultados de um modelo

Evolução do apoio computadorizado à Análise/Ciência de dados

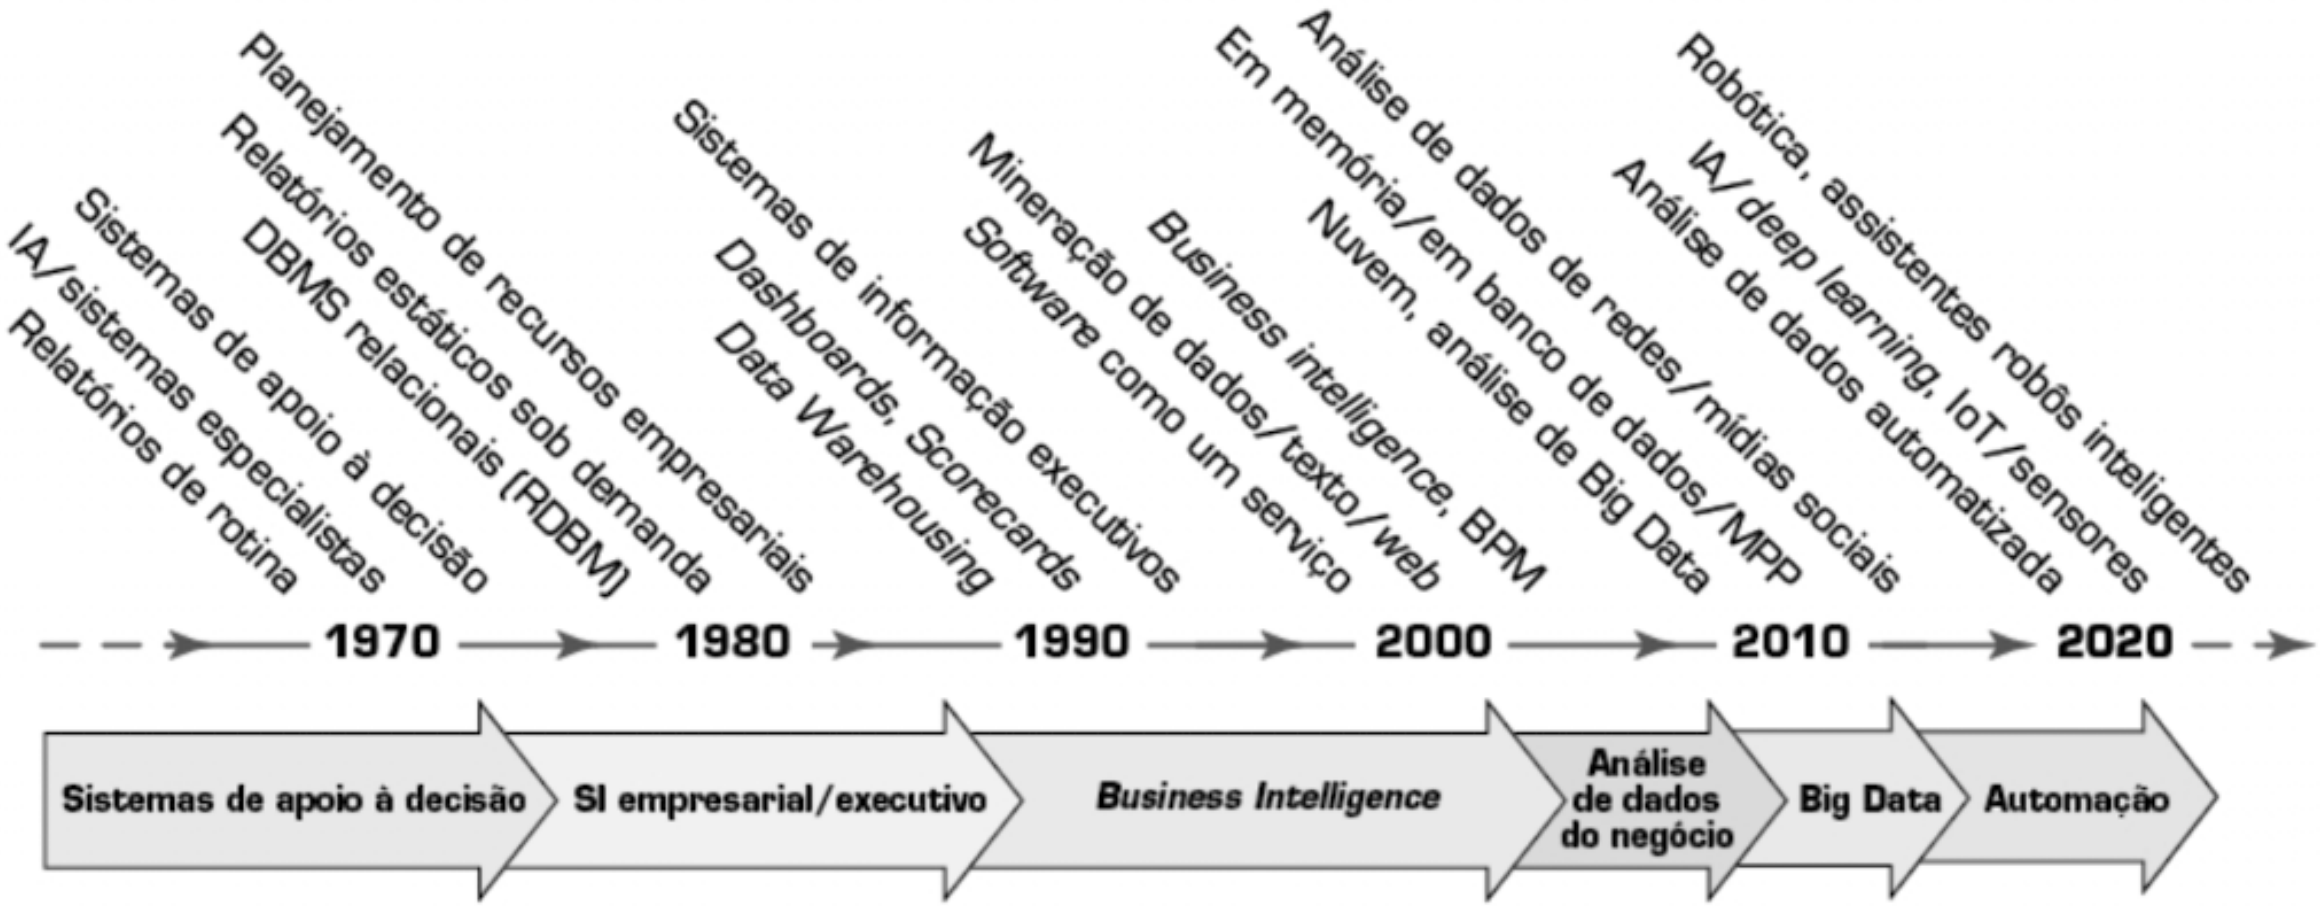

FIGURA 1.18 Evolução do apoio à decisão, *business intelligence*, análise de dados e IA.

IA: inteligência artificial; DBMS: sistemas de gerenciamento de bancos de dados; RDBM: gerenciamento de dados relacionais; BPM: gestão do desempenho do negócio; MPP: processamento paralelo massivo; SI: sistemas de informação; IoT: Internet das Coisas.

Link para discussão:https://www.1x.tech/neo

Evolução da Inteligência de Negócios

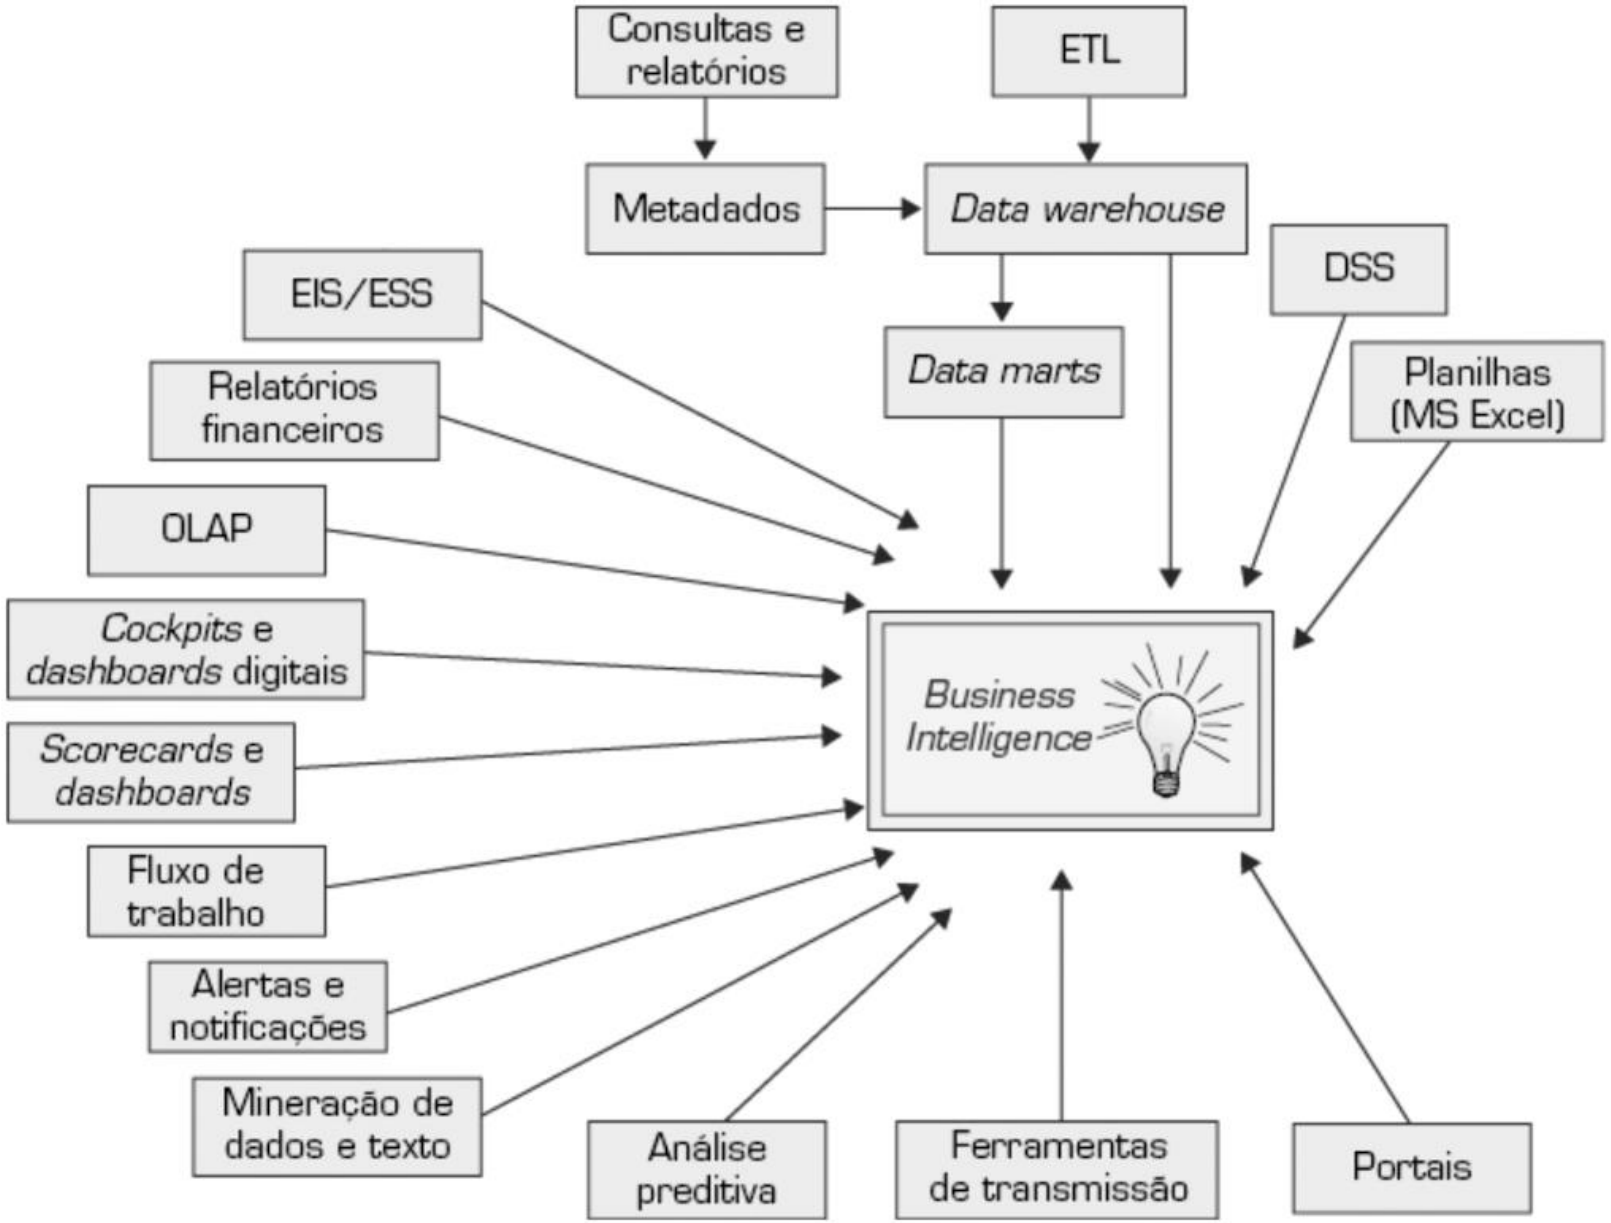

Arquitetura de Inteligência de Negócios

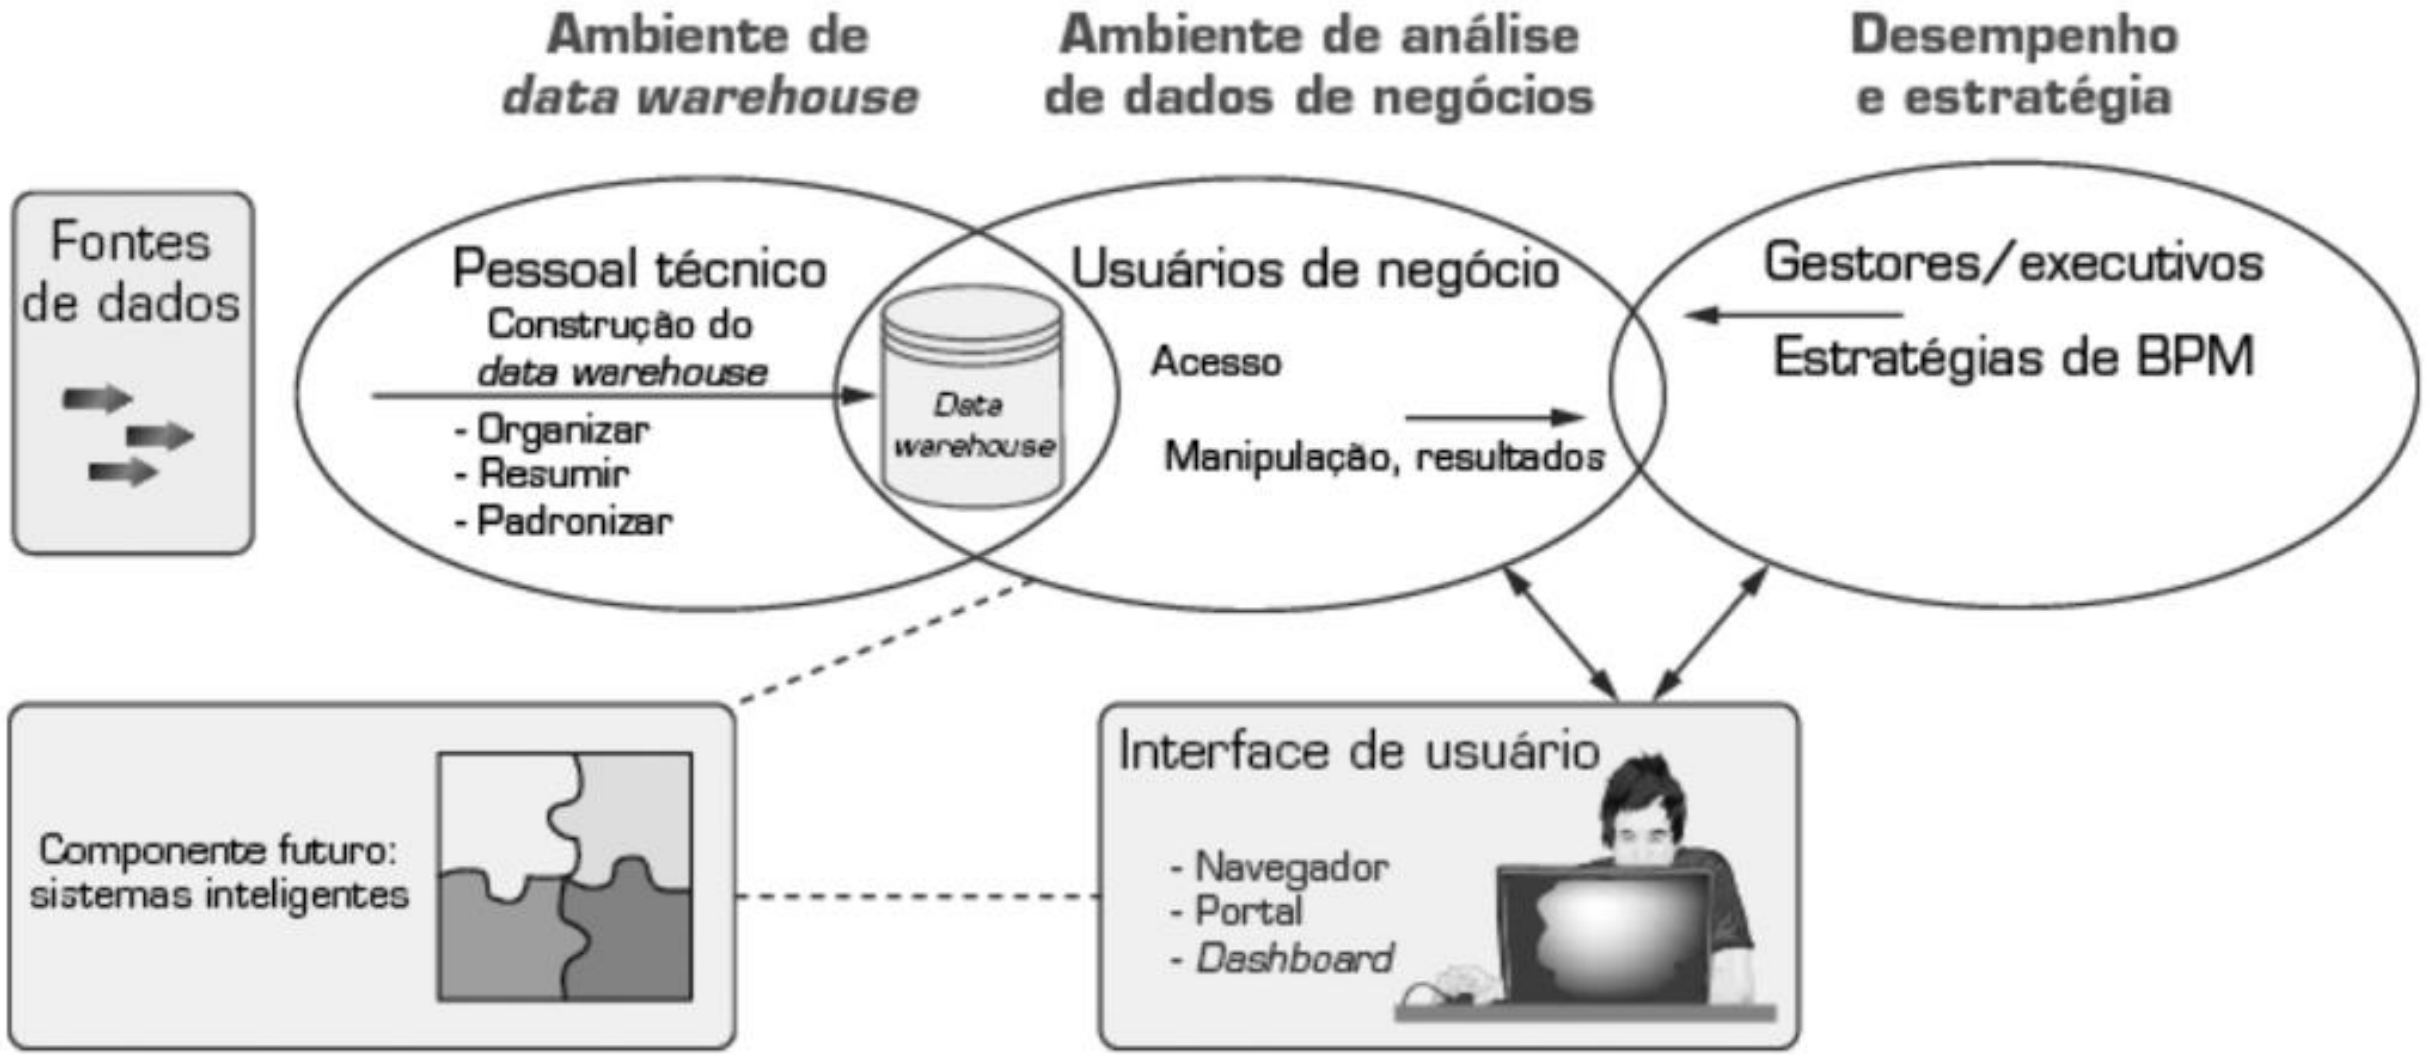

Análise exploratória de dados

Análise exploratória: Fonte e formatos de dados

Images, videos, audio, Flash, live streams, podcasts, etc.

Twitter, Linkedin, Facebook, Tumblr, Blog, SlideShare, YouTube, Google+, Instagram, Flickr, Pinterest, Vimeo, WordPress, IM, RSS, Review, Chatter, Jive, Yammer, etc.

XLS, PDF, CSV, email, Word, PPT, HTML, HTML 5, plain text, XML, JSON, etc.

Medical devices, smart electric meters, car sensors, road cameras, satellites, traffic recording devices, processors found within vehicles, video games, cable boxes, assembly lines, office building, cell towers, jet engines, air conditioning units, refrigerators, trucks, farm machinery, etc..

Government, weather, competitive, traffic, regulatory, compliance, health care services, economic, census, public finance, stock, OSINT, the World Bank, SEC/Edgar, Wikipedia, IMDb, etc.

Event logs, server data, application logs, business process logs, audit logs, call detail records (CDRs), mobile location, mobile app usage, clickstream data, etc.

Archives of scanned documents, statements, insurance forms, medical record and customer correspondence, paper archives, and print stream files that contain original systems of record between organizations and their customers

Project management, marketing automation, productivity, CRM, ERP content management system, HR, storage, talent management, procurement, expense management Google Docs, intranets, portals, etc.

Variáveis e observações

Variáveis

Observações

	Idade	Sexo	Peso	Cor dos olhos
Indivíduo 1	42	M	59	Verde
Indivíduo 2	34	M	54	Castanho
Indivíduo 3	56	F	89	Azul
Indivíduo 4	41	M	76	Castanho
Indivíduo 5	23	F	65	Castanho

Análise exploratória: Dados

Tipos de Dados

- Os conjuntos de dados são compostos por dois tipos de dados: dados **qualitativos** e dados **quantitativos**

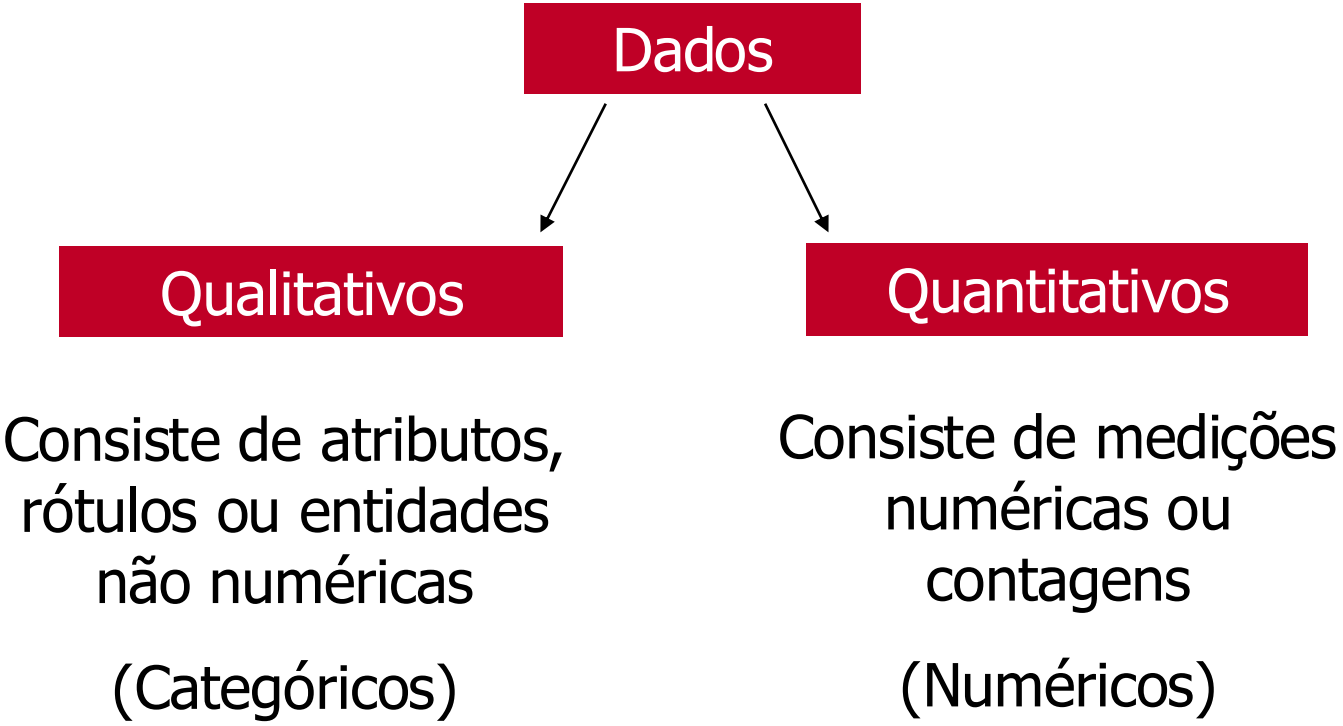

Análise exploratória: Dados Quantitativos

Descrevendo os dados numericamente

Descrevendo os dados numericamente

- **Centralidade e Posição**
  - Média
  - Mediana
  - Moda
  - Média Ponderada
  - Percentís
  - Quartis
- **Dispersão**
  - Amplitude
  - Invervalo interquartil
  - Variância
  - Desvio Padrão

Medidas de posições

Medidas de Posição

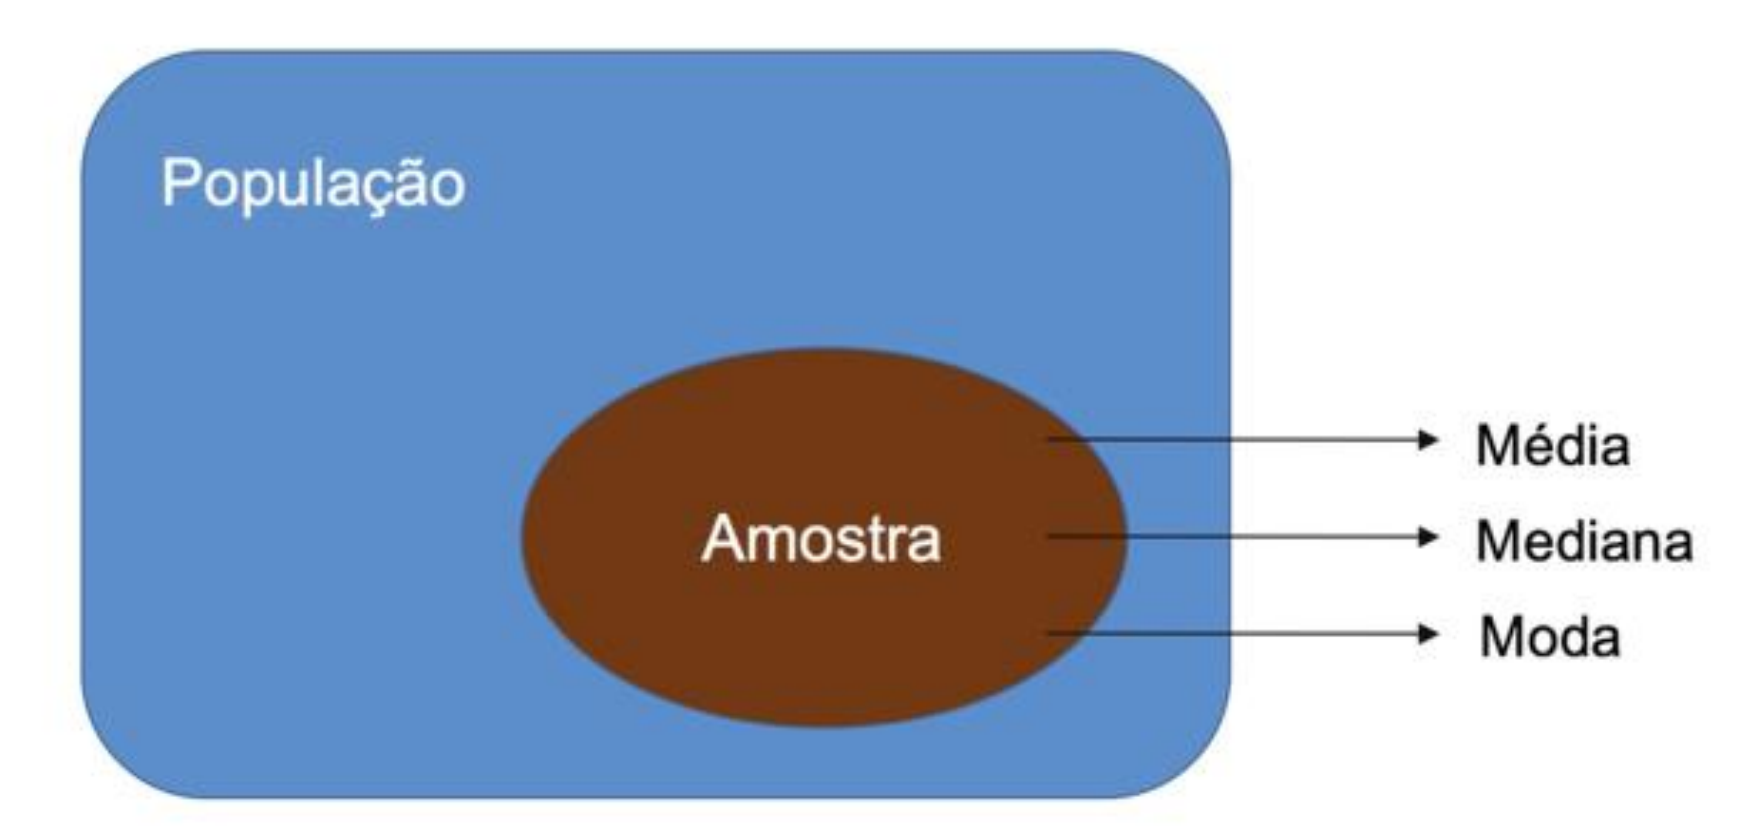

Medida de posição: Média

Média

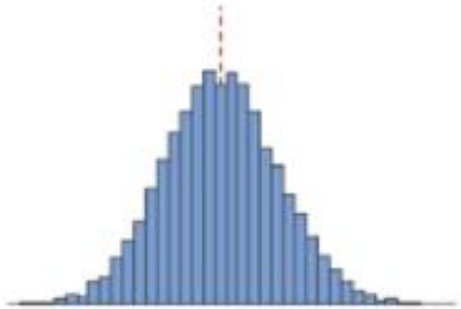

Sem dúvida, **médias** são as formas mais simples de identificar tendências em um conjunto de dados

Cuidado! Outliers podem impactar o valor

Medidas de posição: Mediana

Divide os elementos da amostra ao meio. 50% são menores que a mediana e 50% da amostra maiores.

Mediana

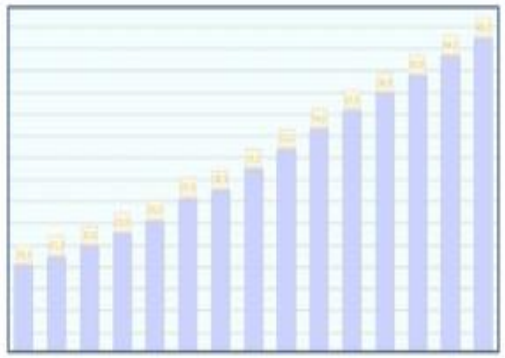

Se o número de elementos n na amostra for ímpar, a Mediana será: (n + 1) /2

Se o número de elementos n na amostra for par, a Mediana será: (n / 2) + 1

- A **mediana** pode ser mais representativa, pois **não é afetada por outliers**.

🎯 **Exemplo:**
Se um grupo de 10 pessoas tem salários de **R$ 2.000 a R$ 5.000**, mas um CEO ganha **R$ 100.000**, a média será **muito maior** do que a maioria ganha, distorcendo a realidade.

Moda

- Valor de maior Frequência na amostra

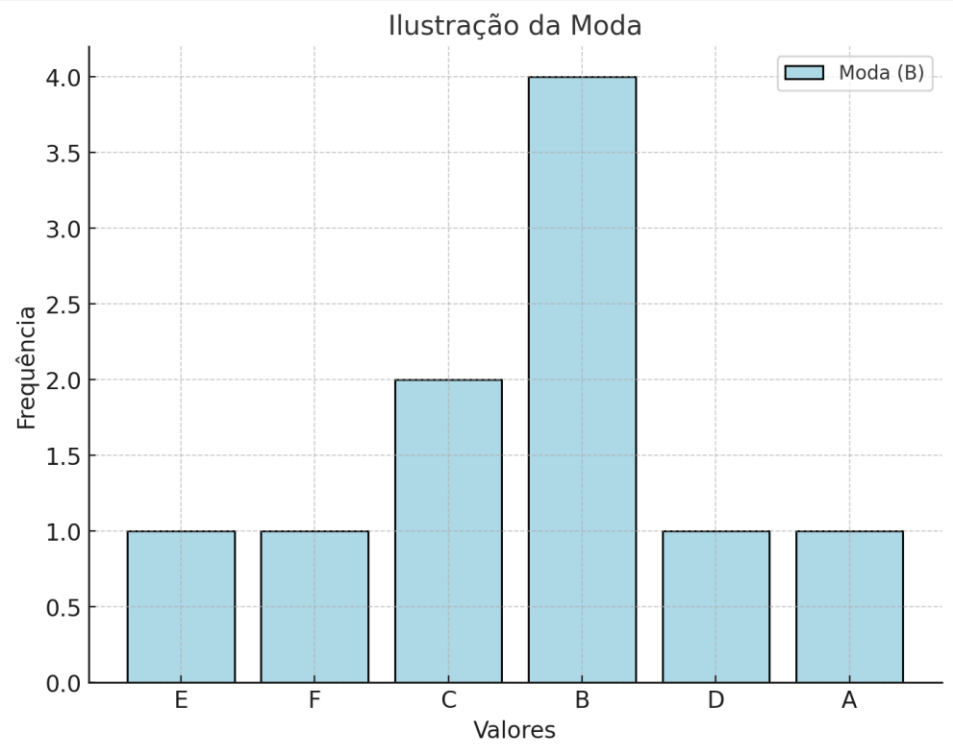

O gráfico de barras mostra a **frequência** dos valores em um conjunto de dados

- O valor **B** aparece **4 vezes**, sendo o mais frequente
- Esse valor é a **moda**, ou seja, o elemento que mais se repete na distribuição

Calculando posições com Power BI

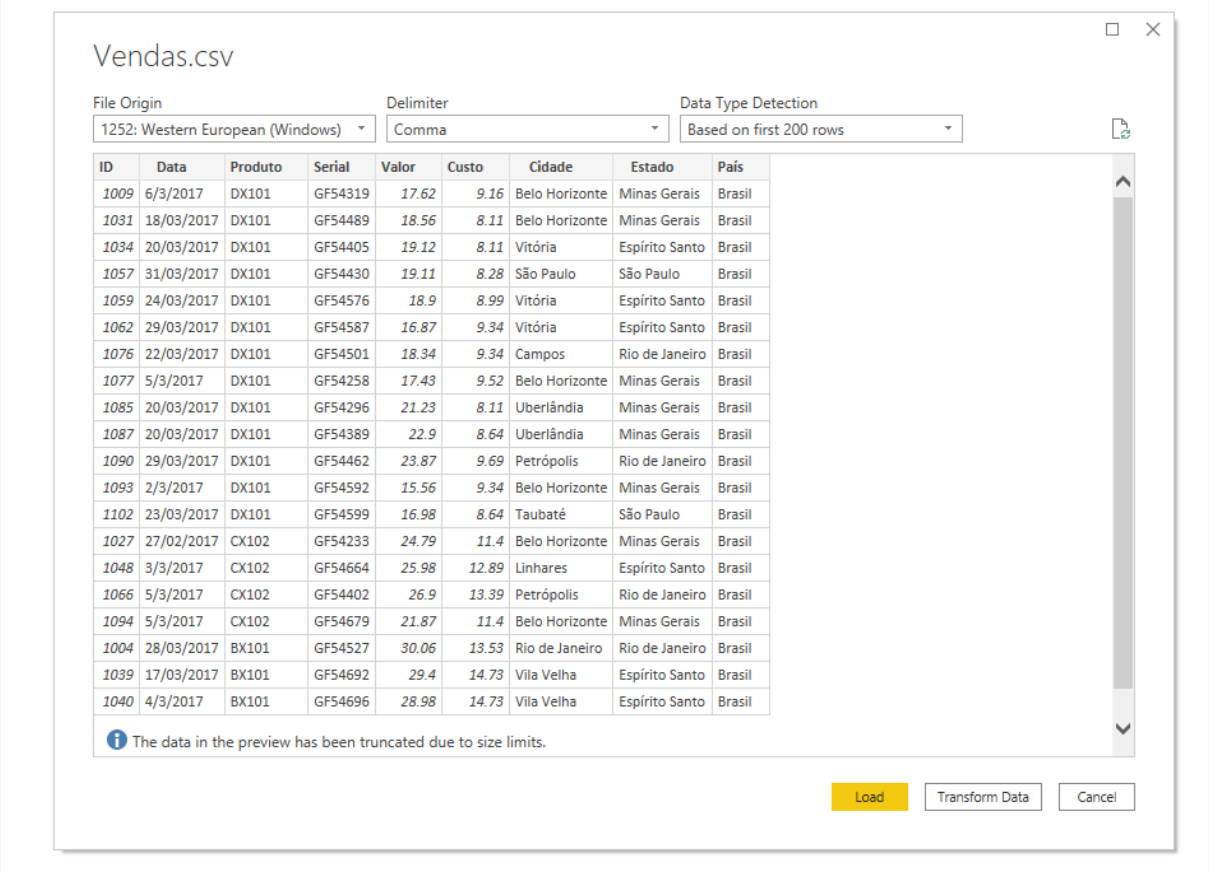

ID	Data	Produto	Serial	Valor	Custo	Cidade	Estado	País
1009	6/3/2017	DX101	GF54319	17.62	9.16	Belo Horizonte	Minas Gerais	Brasil
1031	18/03/2017	DX101	GF54489	18.56	8.11	Belo Horizonte	Minas Gerais	Brasil
1034	20/03/2017	DX101	GF54405	19.12	8.11	Vitória	Espírito Santo	Brasil
1057	31/03/2017	DX101	GF54430	19.11	8.28	São Paulo	São Paulo	Brasil
1059	24/03/2017	DX101	GF54576	18.9	8.99	Vitória	Espírito Santo	Brasil
1062	29/03/2017	DX101	GF54587	16.87	9.34	Vitória	Espírito Santo	Brasil
1076	22/03/2017	DX101	GF54501	18.34	9.34	Campos	Rio de Janeiro	Brasil
1077	5/3/2017	DX101	GF54258	17.43	9.52	Belo Horizonte	Minas Gerais	Brasil
1085	20/03/2017	DX101	GF54296	21.23	8.11	Uberlândia	Minas Gerais	Brasil
1087	20/03/2017	DX101	GF54389	22.9	8.64	Uberlândia	Minas Gerais	Brasil
1090	29/03/2017	DX101	GF54462	23.87	9.69	Petrópolis	Rio de Janeiro	Brasil
1093	2/3/2017	DX101	GF54592	15.56	9.34	Belo Horizonte	Minas Gerais	Brasil
1102	23/03/2017	DX101	GF54599	16.98	8.64	Taubaté	São Paulo	Brasil
1027	27/02/2017	CX102	GF54233	24.79	11.4	Belo Horizonte	Minas Gerais	Brasil
1048	3/3/2017	CX102	GF54664	25.98	12.89	Linhares	Espírito Santo	Brasil
1066	5/3/2017	CX102	GF54402	26.9	13.39	Petrópolis	Rio de Janeiro	Brasil
1094	5/3/2017	CX102	GF54679	21.87	11.4	Belo Horizonte	Minas Gerais	Brasil
1004	28/03/2017	BX101	GF54527	30.06	13.53	Rio de Janeiro	Rio de Janeiro	Brasil
1039	17/03/2017	BX101	GF54692	29.4	14.73	Vila Velha	Espírito Santo	Brasil
1040	4/3/2017	BX101	GF54696	28.98	14.73	Vila Velha	Espírito Santo	Brasil

Carregue o arquivo Vendas.CSV

Clique no data view e crie as medidas (modelagem)

Criando as medidas com formulas e DAX (media,mediana e moda)

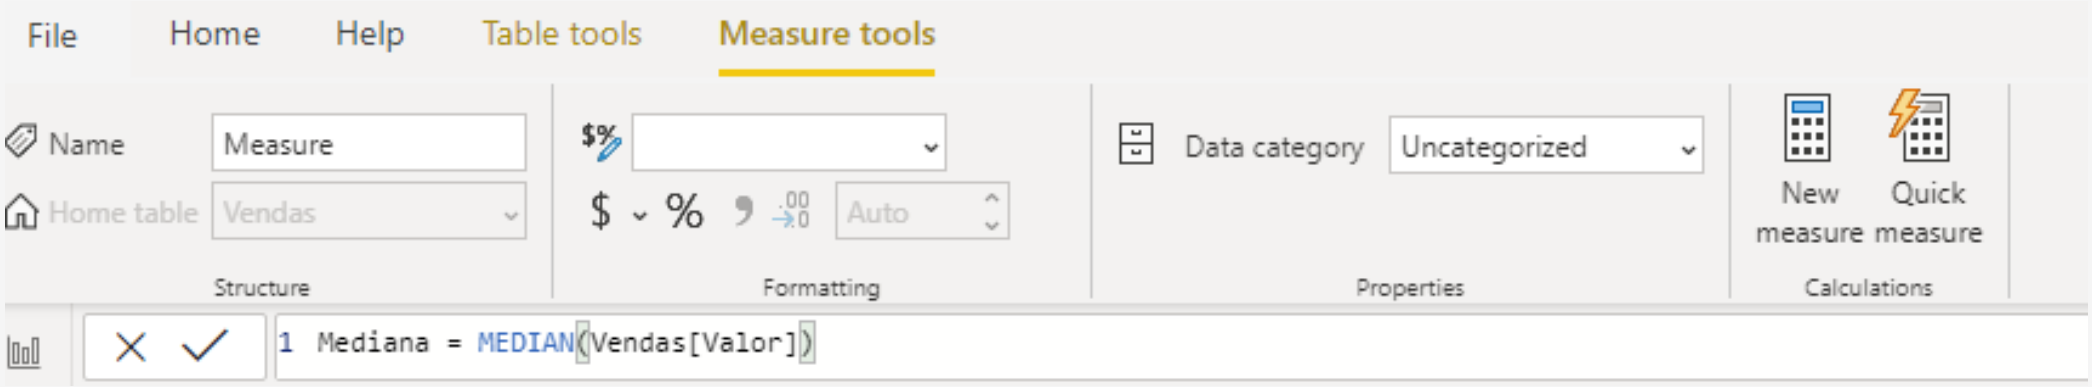

Mode

The mode is the value that appears most often in a set of data. The formula ignores blank values, which are not considered part of the population. The result is identical to the MODE and MODE.SNGL functions in Excel, which return only the minimum value when there are multiple modes in the set of values considered. The Excel function MODE.MULT would return all of the modes, but you cannot implement it as a measure in DAX.

```
Mode :=
MINX (
    TOPN (
        1,
        ADDCOLUMNS (
            VALUES ( Data[Value] ),
            "Frequency", CALCULATE ( COUNT ( Data[Value] ) )
        ),
        [Frequency],
        0
    ),
    Data[Value]
)
```

Substitua por Vendas[valor]

O código pode ser dividido nas seguintes partes:

- **Criar uma tabela com valores únicos e contar a frequência de cada valor**
- **Ordenar os valores pela frequência e selecionar o mais frequente**
- **Retornar o menor valor caso haja empate**

Visualizando as medidas

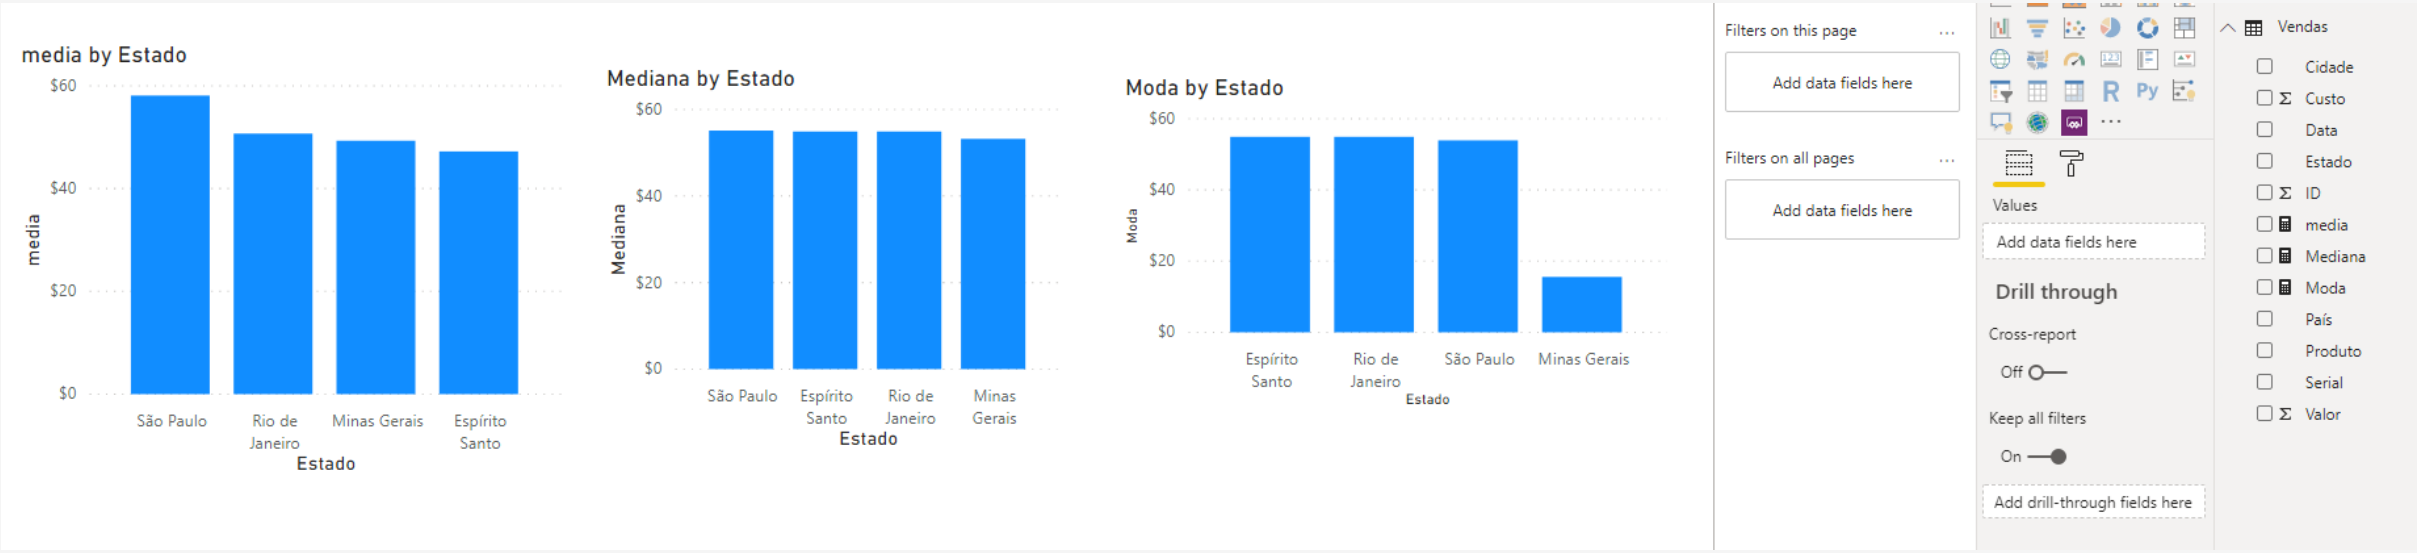

Tabela de Frequência

Tabela de frequência

- Medidas de posição:
  - Média, moda e mediana
- Medidas de dispersão (quão dispersos em relação à medida central):
  - Desvio padrão e variância

- Estas medidas são boas em amostras e para selecionar uma amostra é necessário usar uma Tabela de Frequência

A Tabela de Frequência indica a frequência observada, ou seja, mostra a frequência com que cada observação aparece nos dados.

Tabela de frequência

Para descrevermos um conjunto de dados, definiremos o que são classes de frequência, isto é, intervalos da variável de interesse, e verificaremos o número de dados neste intervalo.

Isso nos dá a Distribuição de Frequência, que é a associação das frequências aos valores obtidos correspondentes.

Para criar uma tabela de frequência, precisamos definir:

Número de classes
Amplitude das classes
Ponto inicial

Tabela de frequência

A frequência pode ser:

- Absoluta
- Relativa

Exercício	frequência absoluta	frequência relativa
nenhum	185	40,04%
mudando	213	46,10%
baixo/ moderado	49	10,61%
alto	15	3,25%

Frequência Acumulada

É o total acumulado (soma) de todas as classes anteriores até a classe atual.

Criando tabela de frequência com o Power BI

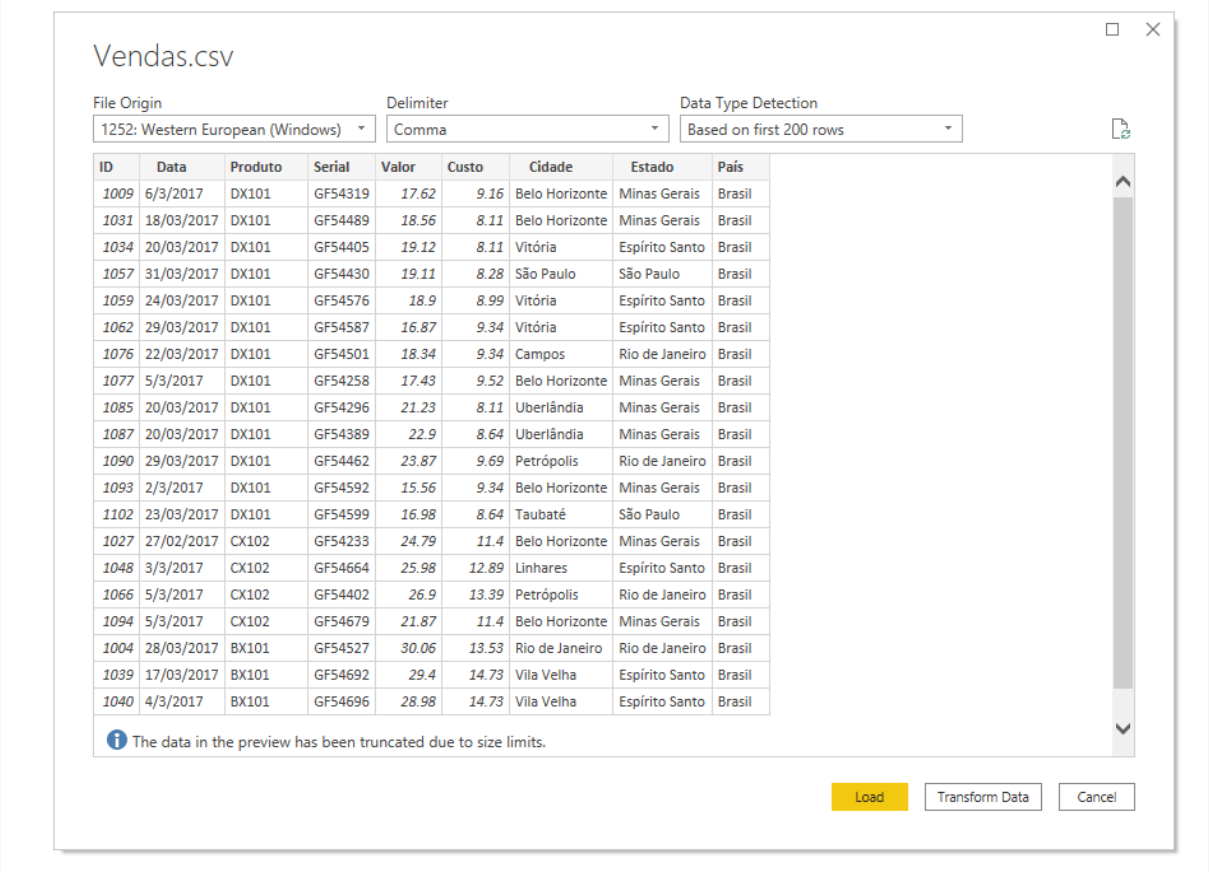

ID	Data	Produto	Serial	Valor	Custo	Cidade	Estado	País
1009	6/3/2017	DX101	GF54319	17.62	9.16	Belo Horizonte	Minas Gerais	Brasil
1031	18/03/2017	DX101	GF54489	18.56	8.11	Belo Horizonte	Minas Gerais	Brasil
1034	20/03/2017	DX101	GF54405	19.12	8.11	Vitória	Espírito Santo	Brasil
1057	31/03/2017	DX101	GF54430	19.11	8.28	São Paulo	São Paulo	Brasil
1059	24/03/2017	DX101	GF54576	18.9	8.99	Vitória	Espírito Santo	Brasil
1062	29/03/2017	DX101	GF54587	16.87	9.34	Vitória	Espírito Santo	Brasil
1076	22/03/2017	DX101	GF54501	18.34	9.34	Campos	Rio de Janeiro	Brasil
1077	5/3/2017	DX101	GF54258	17.43	9.52	Belo Horizonte	Minas Gerais	Brasil
1085	20/03/2017	DX101	GF54296	21.23	8.11	Uberlândia	Minas Gerais	Brasil
1087	20/03/2017	DX101	GF54389	22.9	8.64	Uberlândia	Minas Gerais	Brasil
1090	29/03/2017	DX101	GF54462	23.87	9.69	Petrópolis	Rio de Janeiro	Brasil
1093	2/3/2017	DX101	GF54592	15.56	9.34	Belo Horizonte	Minas Gerais	Brasil
1102	23/03/2017	DX101	GF54599	16.98	8.64	Taubaté	São Paulo	Brasil
1027	27/02/2017	CX102	GF54233	24.79	11.4	Belo Horizonte	Minas Gerais	Brasil
1048	3/3/2017	CX102	GF54664	25.98	12.89	Linhares	Espírito Santo	Brasil
1066	5/3/2017	CX102	GF54402	26.9	13.39	Petrópolis	Rio de Janeiro	Brasil
1094	5/3/2017	CX102	GF54679	21.87	11.4	Belo Horizonte	Minas Gerais	Brasil
1004	28/03/2017	BX101	GF54527	30.06	13.53	Rio de Janeiro	Rio de Janeiro	Brasil
1039	17/03/2017	BX101	GF54692	29.4	14.73	Vila Velha	Espírito Santo	Brasil
1040	4/3/2017	BX101	GF54696	28.98	14.73	Vila Velha	Espírito Santo	Brasil

Carregue o arquivo Vendas.CSV

Clique no data view e crie as medidas (modelagem)

Tabela de frequência de vendas por estado

- Insira a visualização TABELA
- Insira os campos estado e valor
- Veja que as estatísticas (media, variância e mediana) podem ser obtidas facilmente através das propriedades dos campos

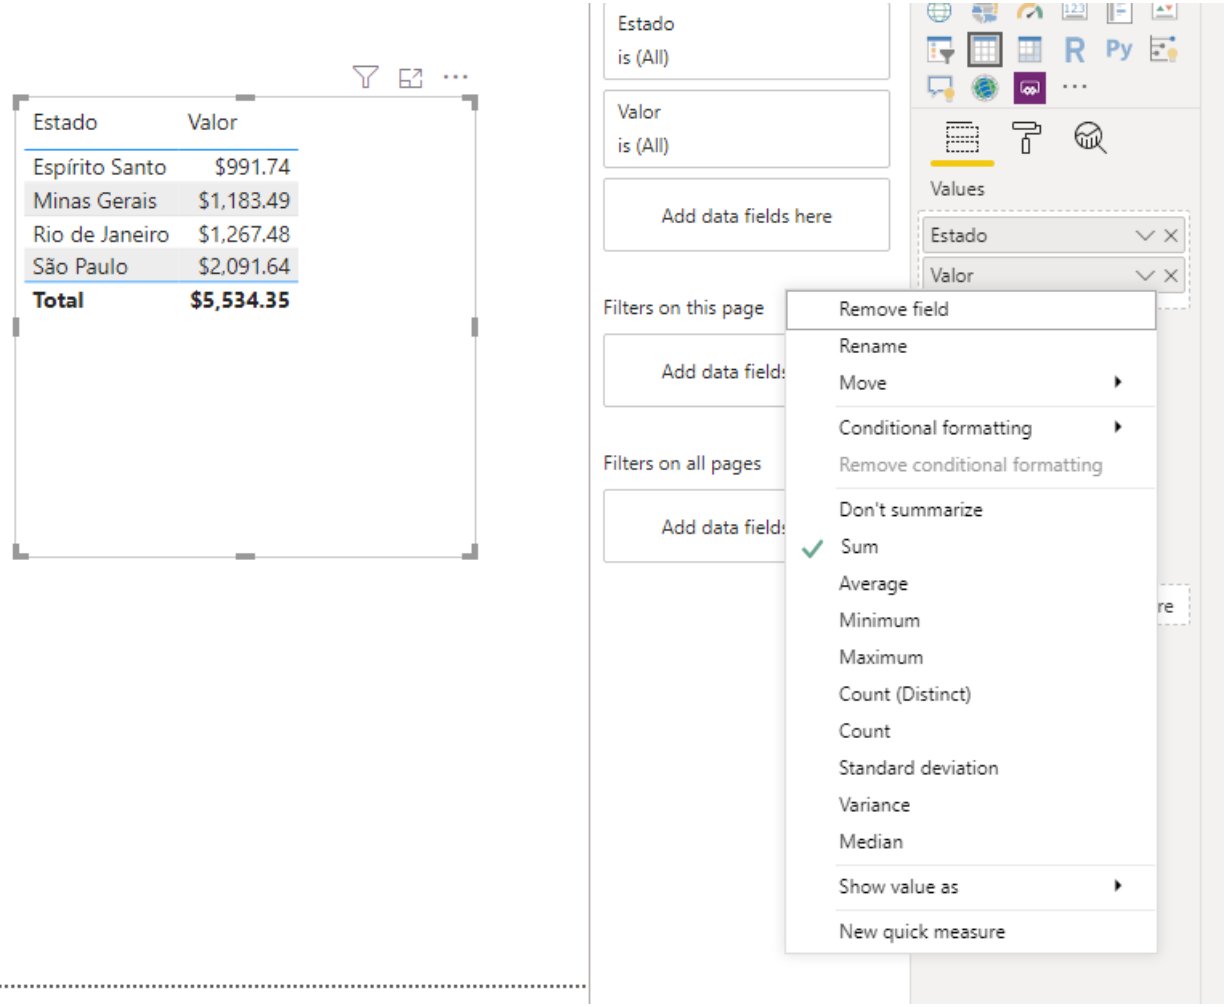

Tabela de frequência de vendas por estado

- Altere a medida para CONTAGEM
- Altere para visualizar em percentual

Estado	Count of Valor
Espírito Santo	21
Minas Gerais	24
Rio de Janeiro	25
São Paulo	36
Total	**106**

Frequência absoluta

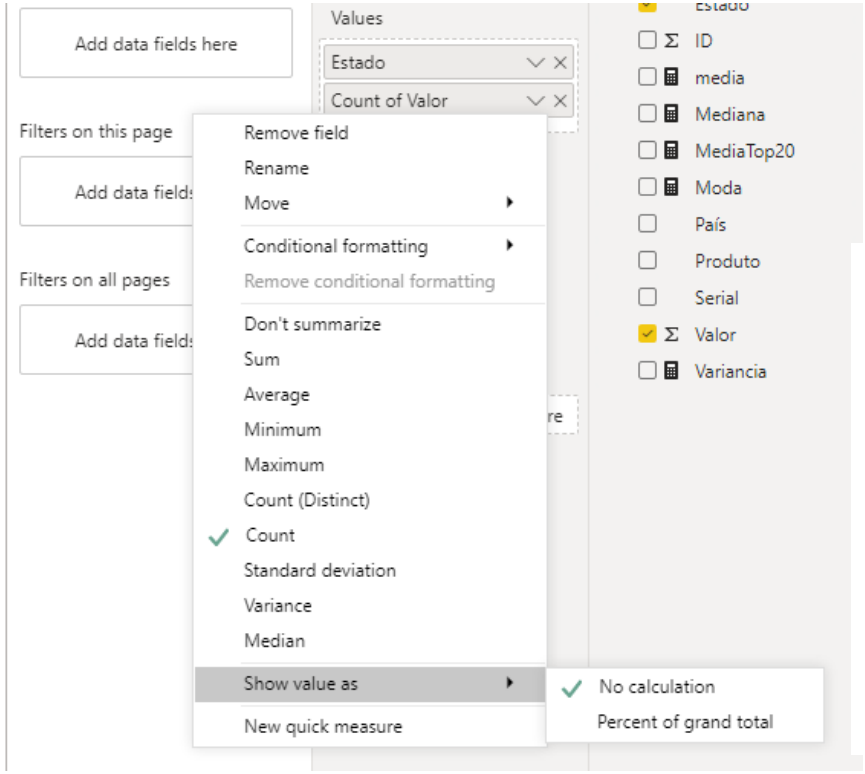

Frequência relativa

Estado	%GT Count of Valor
Espírito Santo	19.81%
Minas Gerais	22.64%
Rio de Janeiro	23.58%
São Paulo	33.96%
Total	**100.00%**